



LAPORAN PENELITIAN OPSI

**Prediksi Peptida Imunogenik untuk Imunitas Sel-T sebagai Epitop
Potensial *Targeted-Vaccine* dan *Targeted-Immunotherapy* pada Kanker Paru
Berbasis *Deep Learning* Menggunakan Algoritma *Convolutional Neural
Network (CNN)***

MIRRABELL FREDERICA HADIWIJONO (0071608262)

I NYOMAN AGUNG ANANDA TERANO (0073976630)

Bidang Kompetisi Penelitian:

Fisika Terapan dan Rekayasa (FTR)

SMA Negeri 4 Denpasar

Kota Denpasar, Bali

Tahun 2024

ABSTRAK

Jumlah penderita kanker paru di Indonesia meningkat pesat hingga menduduki urutan ke-8 di Asia tenggara dengan peningkatan dalam lima tahun terakhir sebanyak 10.85%. Ketidakjelasan gejala kanker paru pada tahap awal membuat deteksi dini kanker cukup rumit dan mayoritas ditemukan setelah menginjak stadium lanjut. Strategi *targeted-immunotherapy* merupakan pendekatan terbaru dalam manajemen kanker dengan cara 'memprogram ulang' kekebalan tubuh pasien. Metode komputasi sangat penting dalam perancangan *targeted-immunotherapy* untuk memprediksi peptida non-alami yang dapat memicu respons sel-T. Selain itu diperlukan pengembangan *targeted-vaccine* untuk mencegah kanker paru-paru pada individu yang belum terdiagnosis. Namun, saat ini kita masih kekurangan metode prediksi imunogenisitas yang akurat. Tantangan lain adalah kemampuan mensimulasikan peptida imunogenik secara tepat untuk alel antigen leukosit manusia (HLA). Maka dari itu, peneliti menciptakan suatu inovasi menggabungkan kecerdasan buatan khususnya *deep learning* dalam memprediksi peptida imunogenik yang berfokus pada penyakit kanker paru. Peneliti menggunakan metode *convolutional neural network* (CNN) dan mengusulkan modifikasi lapisan konvolusi dua dimensi (*Conv2D*) untuk menangkap pola spasial atau sekuensial dalam data peptida dengan lebih akurat. Dataset menggunakan 4990 data input dengan 4491 data pelatihan dan 499 data validasi. Dari empat varian alel yang digunakan didapatkan bahwa alel HLA-C*0701 dan HLA*0201 merupakan alel terbaik untuk mengikat peptida imunogenik pada kanker paru. Berdasarkan hasil *confusion matrix* didapatkan rata-rata skor akurasi sebesar 94%, presisi sebesar 92%, spesifisitas sebesar 86%, *recall* sebesar 98%, dan *f-1 score* sebesar 95% dengan nilai kurva AUC sebesar 0,9. Hasil tersebut menunjukkan bahwa modifikasi model berhasil mendapatkan performa yang sangat baik dalam memprediksi peptida imunogenik.

Kata Kunci: *Deep learning*, *convolutional neural network* (CNN), *targeted-immunotherapy*, *targeted-vaccine*, peptida imunogenik.

DAFTAR ISI

ABSTRAK.....	i
BAB 1. PENDAHULUAN.....	1
1.1 LATAR BELAKANG.....	1
1.2 RUMUSAN MASALAH.....	2
1.3 TUJUAN PENELITIAN.....	2
1.4 HIPOTESIS	2
1.5 MANFAAT PENELITIAN	2
BAB 2. TINJAUAN PUSTAKA	3
2.1 Landasan Teori.....	3
2.1.1 Kanker Paru	3
2.1.2 Targeted-Immunotherapy	3
2.1.3 Targeted-Vaccine.....	3
2.1.4 Sel-T	3
2.1.5 Peptida	4
2.1.6 MHC (Major Histocompatibility Complex)	4
2.1.7 Deep Learning.....	5
2.1.8 Convolutional Neural Network (CNN).....	5
2.2 Kajian Empiris	5
BAB 3. METODE PENELITIAN	6
3.1 Waktu dan Tempat Penelitian.....	6
3.2 Alat dan Bahan Penelitian.....	6
3.3 Jenis Penelitian	6
3.4 Variabel Penelitian	6
3.5 Prosedur Penelitian	6
3.6 Proses Analisis Data.....	9
3.6.1 Metrik Evaluasi Kerja.....	9
3.7 Analisis Varian Alel HLA (<i>Human Leukocyte Antigen</i>).....	10
BAB 4. HASIL DAN PEMBAHASAN	11
4.1 Hasil.....	11
4.2 Pembahasan	13
BAB 5. KESIMPULAN DAN SARAN	15
5.1 Kesimpulan	15
5.2 Saran	15
UCAPAN TERIMAKASIH.....	iii
DAFTAR PUSTAKA.....	iv
LAMPIRAN	vi

BAB 1. PENDAHULUAN

1.1 LATAR BELAKANG

Kanker paru merupakan suatu penyakit keganasan pada paru dimana terjadi proliferasi sel yang tidak terkendali disebabkan oleh perubahan genetika pada sel epitel saluran nafas (Buana dan Harahap, 2022). Kanker paru-paru merupakan penyebab utama kejadian dan kematian akibat kanker di seluruh dunia (Thandra dkk., 2021). Berdasarkan prediksi statistik *International Agency for Research on Cancer* (IARC), tingkat mortalitas mencapai 1,8 juta. Jumlah penderita kanker paru di Indonesia meningkat pesat hingga menduduki urutan ke-8 di Asia Tenggara dengan peningkatan dalam lima tahun terakhir sebanyak 10.85% (Kementerian Kesehatan Republik Indonesia, 2019). Berbagai penelitian terkait tatalaksana kanker paru telah dikembangkan seperti pembedahan reseksi, kemoterapi, dan radiasi. Namun, karena ketidakjelasan gejala kanker paru pada tahap awal membuat deteksi dini kanker cukup rumit dan mayoritas ditemukan setelah menginjak stadium lanjut (Rahman dkk., 2023). Hal ini menyebabkan pengobatan menjadi kurang efektif serta tingginya resistensi terhadap terapi. Selain itu, saat ini pengembangan terapi hanya berfokus pada terapi definitif tanpa adanya upaya preventif.

Strategi *targeted-immunotherapy* merupakan pendekatan terbaru dalam manajemen kanker dengan cara 'memprogram ulang' kekebalan tubuh pasien. Manajemen ini mampu secara efektif memprediksi neo-peptida spesifik dari kanker yang paling mungkin untuk memberikan respon imun. Selain itu, manajemen ini dapat pula dikembangkan untuk memprediksi imunogenisitas peptida yang terikat pada MHC-I dimana berperan dalam mengatur pengarahannya aktivasi sel-T untuk membunuh sel kanker dan menyeleksi patogen yang presisi sehingga dapat pula dikembangkan menjadi *targeted-vaccine* (Li dkk., 2021). Respon imun spesifik sel-T akan dipicu jika peptida mampu berikatan dengan molekul *Major Histocompatibility Complex* (MHC) serumpun, peptida yang memenuhi kriteria ini disebut sebagai peptida imunogenik dimana paparan sinyal 'asing' memicu immuno reseptor tirosin pada sel-T menjadi terfosforilasi dan mengaktifkan respon imun (Jogeklar, 2020). Proses ini pada akhirnya mengakibatkan kematian sel yang ditargetkan dari sel pengekspres antigen oleh sel-T CD8+. Oleh karena itu, pengembangan *targeted-vaccine* melalui identifikasi epitop imunogenik yang dapat memicu respons sel-T dapat menjadi metode efektif untuk mencegah kanker paru-paru pada individu yang belum terdiagnosis.

Namun, pengembangan ini terkendala karena memerlukan waktu yang lama dan biaya yang mahal untuk memprediksi ikatan peptida dengan MHC (Mandasari, 2015). Selain itu, prediksi pengikatan MHC saja tidak cukup untuk menyimpulkan imunogenisitas karena alat tersebut tidak memodelkan peptida mana yang akan memicu respon sel-T. Maka dari itu, peneliti menciptakan suatu inovasi dengan mengaplikasikan metode *in silico* berupa kecerdasan buatan *deep learning* untuk memprediksi imunogenisitas peptida guna mengisi kesenjangan dan melengkapi alat prediksi saat ini. Data peptida dan alel *Human Leukocyte Antigen* (HLA) akan diolah menggunakan algoritma khusus yang disebut *Convolutional Neural Network* (CNN). Peneliti menggunakan metode arsitektur *Convolutional Neural Network* (CNN) untuk mengekstraksi karakteristik yang krusial dari sekuens peptida dalam memahami hubungan antara struktur peptida dan respons imunologis yang dihasilkan. Metode CNN memiliki keunggulan dalam mengenali pola hirarkis dalam urutan asam amino yang memungkinkan untuk mengekstraksi fitur-fitur penting tanpa memerlukan ekstraksi fitur manual (Liang dan Li, 2018). Selain itu, CNN memiliki invariansi terhadap pergeseran dan perubahan skala yang memungkinkannya untuk mengenali epitop bahkan jika mereka berada pada posisi atau ukuran yang berbeda dalam urutan asam amino (Tong dkk., 2019).

Hingga saat ini belum ada penelitian yang berfokus dalam memprediksi epitop imunogenik pada kanker paru. Penelitian terdahulu telah menunjukkan upaya untuk memprediksi epitop imunogenik, namun penelitian tersebut belum mempertimbangkan penggunaan peptida dan variasi alel HLA yang spesifik terhadap pasien kanker paru. Kurangnya pendekatan yang spesifik ini, membuat hasil prediksi dari penelitian sebelumnya memiliki kelemahan yang signifikan terhadap subjek yang bersifat spesifik. Selain itu, peneliti berinovasi untuk memodifikasi model arsitektur CNN dengan pendekatan dua dimensi

(*Conv2D*) untuk mendapatkan hasil yang lebih akurat. Konvolusi dua dimensi dapat mengekstraksi fitur hierarkis dan menangkap pola-pola spasial dari sekuens peptida (Raoufi dkk, 2019). Oleh karena itu, penelitian ini bertujuan untuk mengisi celah ini dengan mencoba memprediksi epitop potensial secara akurat yang dapat berfungsi sebagai upaya pencegahan kanker paru.

1.2 RUMUSAN MASALAH

- 1.2.1 Bagaimana modifikasi model arsitektur CNN dalam memprediksi peptida imunogenik kanker paru?
- 1.2.2 Bagaimana efektifitas kinerja model prediksi peptida imunogenik berdasarkan hasil nilai evaluasi metrik?
- 1.2.3 Bagaimana perbandingan kinerja model prediksi peptida imunogenik berbasis CNN dengan model prediksi lainnya dalam konteks pengikatan peptida oleh alel HLA pada kanker paru?
- 1.2.4 Bagaimana karakteristik variasi alel HLA yang berpotensi untuk mengikat peptida kanker paru?

1.3 TUJUAN PENELITIAN

- 1.3.1 Mendeskripsikan modifikasi model arsitektur CNN dalam memprediksi peptida imunogenik kanker paru.
- 1.3.2 Mendeskripsikan keefektifan kinerja model prediksi peptida imunogenik berdasarkan hasil nilai evaluasi metrik.
- 1.3.3 Mendeskripsikan perbandingan kinerja model prediksi peptida imunogenik berbasis CNN dengan model prediksi lainnya dalam konteks pengikatan peptida oleh alel HLA pada kanker paru.
- 1.3.4 Mendeskripsikan karakteristik variasi alel HLA yang berpotensi untuk mengikat peptida kanker paru.

1.4 HIPOTESIS

H_1 = Model *deep learning* dengan algoritma *Convolutional Neural Network* (CNN) terbukti efektif dalam memprediksi peptida kanker paru yang imunogenik berdasarkan hasil nilai evaluasi metrik.

H_0 = Model *deep learning* dengan algoritma *Convolutional Neural Network* (CNN) tidak efektif dalam memprediksi peptida kanker paru yang imunogenik berdasarkan hasil nilai evaluasi metrik.

1.5 MANFAAT PENELITIAN

1.5.1 Manfaat bagi Pemerintah

Penelitian ini diharapkan dapat mendorong pemerintah untuk melakukan riset lebih lanjut terkait teknologi kecerdasan buatan *deep learning* untuk memprediksi peptida imunogenik penyakit lainnya dengan lebih efektif dan memecahkan permasalahan di bidang kesehatan sehingga perkembangan ilmu kedokteran berkembang lebih pesat.

1.5.2 Manfaat bagi Masyarakat

Penelitian ini diharapkan dapat menjadi strategi preventif yang efektif terhadap kanker paru dengan tujuan menurunkan kasus kanker paru secara global serta angka mortalitas. Selain itu, sebagai pengobatan kuratif, pendekatan ini dapat membantu meningkatkan kualitas hidup pasien yang sudah terdiagnosis.

1.5.3 Manfaat bagi Peneliti

Penelitian ini diharapkan dapat memperluas wawasan peneliti di bidang *deep learning* khususnya dalam memprediksi peptida imunogenik dan memberikan pengalaman yang edukatif.

BAB 2. TINJAUAN PUSTAKA

2.1 Landasan Teori

2.1.1 Kanker Paru

Kanker paru merupakan tumor ganas yang berasal dari epitel bronkus atau karsinoma bronkus sehingga terjadi proliferasi sel-Tidak terkendali (Buana dan Harahap, 2022). Menurut Kementerian Kesehatan Republik Indonesia (2018), kasus kanker paru mayoritas disebabkan oleh rokok yang mengandung zat karsinogen dan aliran asap rokok yang menyebabkan gangguan pada mukosa dan epitel saluran nafas. Namun juga terdapat faktor lain seperti polusi udara, paparan radon, genetik dan lingkungan. Terdapat dua jenis kanker paru yaitu yaitu Karsinoma Paru jenis Karsinoma Bukan Sel Kecil (KPKBSK) dan Karsinoma Paru jenis Karsinoma Sel Kecil (PKSK). Gejala yang berkaitan dengan kanker paru di antaranya: batuk, batuk berdarah, nyeri dada, sesak napas, leher bengkak, benjolan pada leher, suara serak, dan berat badan turun. Menurut Wulandari dan Faot (2017) keganasan di paru sering tidak menunjukkan gejala yang khas apabila masih pada tahap stadium awal. Deteksi kanker paru dilakukan dengan beberapa cara yaitu *computed tomography* (CT) dan *biopsy* dengan pemeriksaan mikroskopik menggunakan contoh jaringan tubuh. Diagnosis kanker paru ditegakkan berdasarkan anamnesis, pemeriksaan fisis, pemeriksaan penunjang dan pemeriksaan patologi anatomi. Berbagai penelitian terkait tatalaksana kanker paru telah dikembangkan seperti pembedahan reseksi yaitu pengobatan klasik pada tahap awal; kemoterapi yang dikombinasikan dengan radioterapi diusulkan pada kanker stadium lanjut local (Hermawati dan Safii, 2021).

2.1.2 Targeted-Immunotherapy

Targeted-Immunotherapy adalah jenis imunoterapi yang menggunakan obat dengan melakukan intervensi terhadap target molekuler spesifik yang terlibat dalam progresivitas dan penyebaran dari sel kanker. Terapi ini bersifat *cytostatic* yaitu dapat menghambat proliferasi sel-Tumor dan bekerja pada target molekuler yang spesifik. Meskipun begitu, resistensi terhadap terapi kanker bisa terjadi karena proses evolusi memungkinkan sel kanker untuk mengembangkan bahkan mengubah ekspresi molekuler mereka sehingga tidak lagi terpengaruh oleh terapi yang diberikan (Andayani dan Julisafrida, 2020). Selain dari sisi biologis, faktor seperti penggunaan terapi yang tidak konsisten dan spesifik, juga dapat memengaruhi kemampuan terapi untuk menghambat pertumbuhan kanker. Namun, hambatan tersebut dapat diatasi dengan melakukan pemantauan rutin terhadap respons pasien atau pemanfaatan tes sejenis biomarker untuk menentukan efektivitas terapi terhadap pasien (Smith dan Johnson, 2020).

2.1.3 Targeted-Vaccine

Targeted-vaccine adalah strategi vaksin yang bertujuan untuk memvaksinasi inang secara istimewa sesuai dengan karakteristik epidemiologi tertentu (Gandon dan Lion, 2021). Pendekatan primer vaksin untuk kanker adalah dengan mengaktifkan sel-T spesifik terhadap antigen tumor. Vaksin dapat diberikan sebagai protein rekombinan dengan adjuvant (Abdul dkk. 2016). Saat ini, belum banyak vaksin yang telah disetujui untuk penggunaan klinis dalam pengobatan kanker, disebabkan oleh tantangan dalam mengidentifikasi target yang sesuai, merancang vaksin yang efektif, dan memvalidasi efektivitas mereka dalam uji klinis. Dalam pembuatan *targeted-vaccine* melibatkan teknik rekayasa protein untuk menghasilkan epitop imunogenik yang akan diuji kembali untuk memastikan bahwa mereka dapat merangsang respons kekebalan yang diinginkan. Hal ini melibatkan uji preklinik peptida untuk memeriksa respons imun, termasuk produksi antibodi dan respon seluler.

2.1.4 Sel-T

Menurut *National Cancer Institute* sel-T atau sering disebut limfosit T merupakan suatu jenis sel darah putih yang merupakan bagian dari sistem kekebalan dan perkembangan sel induk di sumsum tulang belakang. Sel-T berperan melindungi tubuh dari infeksi dan membantu melawan kanker. Semua sel-T memiliki TCR (reseptor sel-T) dan koreseptor sel pan-T CD3. TCR sendiri merupakan reseptor transmembran yang terdiri dari berbagai rantai alfa dan beta, masing-masing dengan wilayah yang bervariasi. Variasi ini berkembang untuk mengenali antigen yang berbeda dan diseleksi selama proses

pematangan sel-T. Terdapat beberapa jenis sel-T; yang paling umum yaitu sel-T CD4+ (sel-T pembantu) dan sel-T CD8+ (sel-T sitotoksik atau sel-T pembunuh). Sel-T CD4+ bersifat diam dapat diaktifkan oleh kompleks peptida-MHC kelas II pada APC (*Antigen Presenting Cell*) yang berfungsi memperkuat respon kekebalan tubuh dengan merangsang aktivasi dan proliferasi sel-sel kekebalan tubuh lainnya. Sedangkan sel-T CD8+ berfungsi untuk mengenali dan menghancurkan sel-sel yang terinfeksi virus atau sel kanker. Sel yang mengandung antigen kanker akan mengekspresikan antigennya Bersama molekul MHC kelas I yang kemudian akan membentuk kompleks melalui TCR dan sel-T CD8+, kemudian mengaktifasi sel-TCD8+ untuk menghancurkan sel kanker tersebut (Kondororik, 2017).

2.1.5 Peptida

Peptida merupakan molekul yang terbentuk dari dua atau lebih asam amino. Jika jumlah asam amino masih di bawah 50 molekul disebut peptida, namun jika lebih dari 50 molekul disebut dengan protein. Zat ini memainkan berbagai peran penting yang spesifik di dalam tubuh seperti *chemical messenger*, neurotransmitter serta pemacu dan penghambat metabolisme tertentu. Di dalam sistem kekebalan tubuh manusia, peptida dan antigen berperan penting dalam memicu respons imun terhadap ancaman dari patogen dan bahan asing lainnya. Antigen merupakan zat apa yang menimbulkan respons sel-B atau sel-T. Bagian kecil antigen yang dapat diakses dan diikat reseptor antigen disebut epitop (Lisa dkk., 2020).

2.1.6 MHC (*Major Histocompatibility Complex*)

Major Histocompatibility Complex (MHC) adalah sekelompok gen yang terletak di dalam genom untuk mengatur ekspresi protein dan pengenalan sistem kekebalan tubuh terhadap *self-antigen* dan *non-self-antigen* (Garcia dkk., 2023). Terdapat dua kelas MHC yaitu MHC kelas I dan kelas II. Komplek MHC kelas I berikatan dengan sel-T sitotoksik (CD8+) sedangkan MHC kelas II berikatan dengan sel-T pembantu (CD4+) (Saraswati, 2021). MHC kelas I merupakan molekul glikoprotein permukaan sel yang mengikat peptida yang berasal dari virus pada *reticulum endoplasma* (ER) dan mempresentasikannya pada permukaan sel untuk dipaparkan pada limfosit T sitotoksik dengan perkiraan berat molekul 45 kd. MHC kelas I berfungsi untuk menstimulasi produksi antibodi, prosesing dalam interaksi sel limfosit T dengan antigen, dan bereaksi dalam penolakan jaringan. Proses ikatan antigen dengan MHC kelas I didahului dengan proses degradasi antigen dan MHC. MHC yang sudah terdegradasi akan mengalami resintesa dengan bentuk yang sesuai dengan epitope dan peptida hasil pecahan antigen. Setelah terbentuk kompleks MHC-peptida, peptida akan dibawa ke permukaan sel untuk dipresentasikan kepada sel limfosit T.

2.1.6.1 *Human Leukocyte Antigen* (HLA)

Bagian spesifik dari MHC yang terdapat pada manusia disebut sebagai *Human Leukocyte Antigen* (HLA). Dalam gen-gen HLA, alel merujuk pada variasi genetik yang terdapat pada lokus yang sama pada kromosom homolog. Gen Human Leukocyte Antigen (HLA) menyandi glikoprotein yang berperan pada pembentukan sistem imun manusia. Gen ini terletak pada kromosom 6p21. Secara garis besar, gen HLA dikelompokkan ke dalam HLA kelas I dan HLA kelas II. HLA kelas I terdiri dari locus HLA-A, -B dan -C, sedangkan HLA kelas II terdiri dari HLA-DR, -DQ dan -DP. Variasi ini menyebabkan keanekaragaman alel HLA antar individu dan memegang peranan penting dalam menentukan respons imun terhadap patogen serta kompatibilitas transplantasi. HLA berfungsi dalam mengenali protein asing dari kuman patogen yang masuk ke tubuh. Reaksi imunitas muncul apabila terjadi reaksi diantara kedua molekul tersebut. Ketika interaksi terjadi maka kompleks protein akan dibawa ke permukaan sel untuk dapat dikenali oleh sel-T sehingga mengakibatkan timbulnya respon imun. Oleh karena itu, memprediksi kesesuaian antara protein HLA dan peptida sehingga dapat membentuk ikatan dan timbul suatu respon imun yang dapat dimanfaatkan pada proses pembuatan vaksin didasarkan pada spesifisitas HLA peptida. Vaksin jenis ini terbukti menghasilkan respon imun yang jauh lebih kuat dan lebih aman serta lebih mudah untuk diproduksi. Terdapat dua syarat dalam mewujudkan vaksin jenis tersebut yaitu (1) Molekul HLA sangat selektif dan hanya berikatan dengan peptida yang spesifik dan (2) Molekul HLA sangat polimorfik

dan poligenik. Maka dari itu perlu diketahui dan dikelompokkan alel HLA mana yang dapat berikatan dengan peptida patogen yang spesifik dalam pembuatan vaksin dan terapi (Ser dkk, 2023).

2.1.7 Deep Learning

Deep learning adalah cabang dari *artificial intelligence* dan *machine learning* yang menggunakan *multi-layered neural network* untuk menguasai representasi data yang kompleks dan melakukan prediksi serta pengambilan keputusan (Yuan dkk, 2024). *Multi-layered neural network*, sering disebut sebagai *deep neural network*, merupakan jenis *artificial neural network* (ANN) yang terdiri dari beberapa lapisan neuron yang saling terhubung. Setiap lapisan terdiri dari *nodes*, juga dikenal sebagai neuron, yang memiliki koneksi di lapisan sebelum dan berikutnya untuk pemrosesan informasi. Selain itu, dalam aplikasinya pada pengolahan dalam skala besar, deep learning juga telah menghasilkan kemajuan signifikan, terutama melalui penggunaan Convolutional Neural Networks (CNN) (Gupta dkk., 2022).

2.1.8 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah arsitektur *artificial neural network* (ANN) mengaplikasikan operasi konvolusi dan pooling untuk mengekstraksi fitur spasial dan hierarki data grid, Salah satu jenis *Convolutional Neural Network* (CNN) yang umum digunakan, identik dengan *Multi-Layer Perceptron* (MLP), tersusun atas lapisan konvolusi yang diikuti oleh lapisan sub-sampling (pooling), dengan lapisan *Fully Connected* (FC) sebagai lapisan terakhir. CNN terbagi menjadi beberapa proses yaitu *Forward propagation* berperan untuk menyebar input data melalui *neural network* untuk menghasilkan prediksi, setelah itu *backpropagation* menghitung gradien dari fungsi dan digunakan untuk memperbarui bobot jaringan, terdiri dari *pooling layer*, *dense layer (fully connected)*, *convolutional layer*, dan *batch normalization layer*. Sedangkan *input layer* CNN menampung dimensi data berupa gambar maupun sekuensial data seperti teks melalui serangkaian layer konvolusi, dengan ukuran kernel yang berbeda, menghasilkan representasi vektor yang akan dinormalisasi, diikuti dengan fungsi aktivasi seperti ReLu (Alzubaidi dkk., 2021).

2.2 Kajian Empiris

Adapun landasan penelitian terdahulu yang digunakan dalam penelitian ini, berikut adalah tabel kajian empiris dari penelitian ini:

Tabel 1: Kajian Empiris

No.	Nama Peneliti	Judul Penelitian	Tujuan Penelitian	Hasil Kinerja Model: Nilai ROC-AUC
1.	Trolle T., Nielsen M. 2014	<i>NetTepi: an integrated method for the prediction of T cell epitopes</i>	Menyelidiki menggunakan NetTepi apakah peningkatan akurasi untuk penemuan epitop sel-T dapat dicapai dengan mengintegrasikan prediksi afinitas pengikatan pMHC, stabilitas pMHC, dan kecenderungan sel-T.	ROC-AUC: 0.80
2.	Ogishi M., Yotsuyanagi. 2019	<i>Quantitative Prediction of the Landscape of T Cell Epitope Immunogenicity in Sequence Space</i>	Menghitung sifat fisiokimia berdasarkan meniru termodinamika antara pMHC dan interaksi TCR secara umum.	ROC-AUC: 0,76
3.	Schmidt, dkk. 2021	<i>Prediction of neo-epitope immunogenicity reveals TCRrecognition determinants and provides insight into immunoediting</i>	Memprediksi epitop imunogenik melalui penangkapan dan dekonvolusi sifat molekuler dari presentasi antigen dan kecenderungan pengenalan TCR.	ROC-AUC >0.7

BAB 3. METODE PENELITIAN

3.1 Waktu dan Tempat Penelitian

Penelitian dilaksanakan di laboratorium komputer SMA Negeri 4 Denpasar yang berlokasi di Jalan Gunung Rinjani No.1, Kota Denpasar, Bali sebagai tempat pembuatan dan pengujian model *deep learning*. Penelitian dilaksanakan pada bulan Februari-September 2024. Spesifikasi *timeline* dan rincian kegiatan penelitian tahap perancangan dan pelaksanaan terlampir (Lampiran 1 dan lampiran 2).

3.2 Alat dan Bahan Penelitian

Tabel 2: Spesifikasi Perangkat

Perangkat Keras		Perangkat Lunak <i>Jupyter Notebook</i>	
Spesifikasi	Keterangan	Spesifikasi	Keterangan
<i>Processor</i>	12 th Gen Intel® Core™ i5-1235u	Python	Python 3.12.1
RAM	16 GB	RAM	12.7 GB
<i>Storage</i>	512 GB SSD	<i>Storage</i>	107.7 GB
<i>Graphic Card</i>	NVIDIA GeForce MX550		
<i>Operating System</i>	Windows 11 Home Single Language 64-bit		


3.3 Jenis Penelitian

Penelitian ini menggunakan jenis penelitian kuantitatif eksperimental dan uji akurasi diagnostik untuk mengembangkan penerapan metode *deep learning* menggunakan algoritma CNN dalam memprediksi imunogenitas peptida. Penelitian kuantitatif dilakukan dengan pengembangan model matematis dan algoritma komputasional yang dapat memproses data numerik berupa sekuens rangkaian asam amino dan alel HLA.

3.4 Variabel Penelitian

- Variabel bebas: Rangkaian sekuens asam amino peptida dan alel HLA
- Variabel terikat: Hasil nilai evaluasi metrik
- Variabel kontrol: Kriteria dataset peptida dan alel yang sama

3.5 Prosedur Penelitian



Gambar 1: Prosedur Penelitian

3.5.1 Teknik Pengumpulan Data

Sumber data penelitian ini adalah data sekunder berupa data *sequential* rangkaian asam amino peptida dan alel HLA didapatkan dari *Immune Epitope Database* (IEDB) yang merupakan basis data *open source* yang menyimpan informasi terkait epitop imunogenik. Penelitian ini menggunakan 4990 peptida yang telah diuji tes imunogenisitas molekulernya secara eksperimental dari laman IEDB. Pengambilan dataset dibatasi pada peptida dengan metadata yang cocok dengan kata kunci berikut: (i) Epitop linear, (ii) Uji sel-T, (iii) Kelas MHC I, (iv) *Homo sapiens*, dan (v) Kanker paru. Setelah itu, diterapkan strategi pembersihan data: 1) Data tanpa alel MHC empat digit yang eksplisit dibuang. 2) Alel peptida-MHC yang berlebihan dibuang 3) Semua peptida negatif, tanpa informasi eksperimental eksplisit atau dengan kurang dari empat subjek yang diuji dihapus 4) Peptida dengan panjang 9 dan 10 ditahan untuk pelatihan.

3.5.2 Pre-Processing Data

Pre-processing data merupakan tahap fundamental dalam pemodelan *deep learning*, dan dengan dataset yang kecil seringkali menghasilkan *overfitting* (Oluwasakin dkk., 2023). Salah satu solusi untuk masalah ini adalah paralelisasi data. Data di *pre-process* dengan mengekstrak urutan peptida dan urutan alel HLA dari dataset dan mengubahnya menjadi format numerik.

a. Web Scraping Data Pengikat Antigen (Paratope)

Web scraping adalah proses ekstraksi konten dalam bentuk data atau informasi dari sebuah situs web (Adila, 2022). Data struktural dan sekuensial residu HLA yang terlibat dalam interaksi dengan peptida diperoleh dari *International Immunogenetics Information System 3D (IMGT)*, yang berfokus pada struktural terkait gen reseptor sel-T dan struktur kristal pMHC1 yang telah diselesaikan secara eksperimental (Lefranc *et al.*, 2015). Kemudian, ekstraksi informasi paratope, yaitu residu HLA yang kemungkinan berinteraksi dengan epitope. Pengambilan data dilakukan dengan kriteria: 1) Spesies manusia 2) Tipe pMH1, dan penelitian ini menggunakan 666 entri (Lampiran 3). Selanjutnya dilakukan teknik *web scraping* untuk mengotomatisasi proses pengambilan data menggunakan *Scrapy* and *Selenium*.

b. Pengumpulan dan Input Data

Data yang diperoleh sejumlah 4990 set neoantigen yang terdiri atas 3000 data dengan assay positif (*low-positive, positive, intermediate-positive, high-positive*) dan 1990 data dengan assay negatif. Dataset dibagi menjadi dua yaitu data validasi dan data input, dataset input terdiri dari sekuens peptida dan alel HLA, tanpa assay. Sedangkan, data validasi menyediakan assay dari IEDB yang akan menjadi parameter untuk evaluasi model CNN. Dataset pada google drive akan dimount oleh google colab untuk mengakses dataset dalam bentuk file *.csv*, sebagai *input directory* saat eksekusi file CNN pada *Python*.

c. Normalisasi Indeks Asam Amino

```
def aaindex(peptide, after_pca):  
    amino = 'ARNDCQEGHILKMFPSTWYV-'  
    matrix = np.transpose(after_pca)  
    encoded = np.empty([len(peptide), 12])
```

Gambar 2: Normalisasi Indeks Asam Amino *aaindex*, hasil akan tersimpan pada array *encoded* yang berisi representasi numerik dari peptida berdasarkan indeks asam amino yang telah diubah melalui *Principal Component Analysis (PCA)*.

Function Amino Acid index (AAindex) mengubah representasi indeks asam amino mentah menjadi representasi yang lebih sesuai untuk model pembelajaran mesin, terdiri dari fungsi *pull-peptida-aaindex*, *pull-hla-aaindex* dan *pull-label-aaindex*.

d. Klasifikasi Hierarkhis Alel Human Leucocyte Antigen (HLA)

Untuk mengelola informasi tentang alel HLA yang diketahui. Kamus ini menyimpan informasi berdasarkan jenis alel HLA (A, B, atau C), dua digit pertama dan dua digit terakhir dari alel, fungsi *rescue-unknown-hla* mencoba menangani alel HLA yang tidak diketahui dengan mencari alel terdekat dalam kamus yang dibuat oleh fungsi *dict_inventory* (Lampiran 5). Jika tidak ditemukan alel yang cocok, fungsi ini memilih alel yang paling dekat berdasarkan digit pertama dan terakhirnya.


e. Transformasi DataFrame Peptida dan Human Leucocyte Antigen (HLA)

```
for i in range(ori.shape[0]):  
    peptide = ori['peptide'].iloc[i]  
    hla_type = ori['HLA'].iloc[i]  
    immuno = np.array(ori['immunogenicity']  
                      .iloc[i]).reshape(1,-1)
```

Gambar 3: Transformasi *DataFrame* Peptida dan *Human Leucocyte Antigen (HLA)*


DataFrame (ori) yang berisi informasi *peptida* HLA, dan imunogenisitas dikembalikan dalam sebuah list melalui fungsi *construct_aaindex*. Fungsi ini menerima *DataFrame (ori)* yang berisi informasi tentang peptida (kolom *peptida*), alel HLA, imunogenisitas dan hasil *Principal Component Analysis (PCA)* menjadi *tuple* yang ditambahkan ke dalam list *series*.

3.5.3 Pembuatan Arsitektur Convolutional Neural Network (CNN)



Gambar 4: Konvolusi Kernel dan *Pooling Convolutional Neural Network (CNN)*

Pembuatan arsitektur telah ditentukan berdasarkan bentuk data dan optimalisasi model. Lapisan *Conv2d* dirancang untuk mengekstrak fitur-fitur penting dari data *sequential*. Model ini menggunakan pendekatan *multi-input* di mana input peptida dan HLA diproses secara independen melalui jalur konvolusi terpisah (Alzubaidi dkk., 2021).



Gambar 5: Flowchart Arsitektur Convolutional Neural Network (CNN)

Input 1 akan menerima data berupa representasi numerik dari urutan asam amino peptida dengan panjang urutan maksimal 10 (jumlah asam amino), jumlah fitur untuk setiap asam amino adalah 12, dan 1 saluran data *grayscale*, sedangkan input 2 akan menerima data berupa HLA dengan perbedaan yang hanya terletak pada panjang urutannya yaitu 46.

a. Lapisan *Branch 1*

Lapisan konvolusi 2D pertama dengan 16 filter dan ukuran kernel (2,12) untuk menstabilkan pelatihan dilakukan normalisasi batch dan aktivasi ReLu (*Rectified Linear Unit*), lapisan konvolusi 2D kedua dengan 32 filter dan ukuran kernel (2,1) juga dilakukan normalisasi batch dan aktivasi ReLu untuk mengurangi ukuran spasial output layer *MaxPool2D* dengan ukuran pool (2,1) dan juga strides (2,1). Diakhiri dengan lapisan *flatten* untuk meratakan output *MaxPooling* menjadi vektor 1D.

b. Lapisan *Branch 2*


Branch 2 memiliki struktur yang sama dengan *branch* sebelumnya, tetapi dengan beberapa perbedaan

dengan input berupa representasi HLA. Ukuran kernel pada lapisan konvolusi pertama adalah (15, 12), dan pada lapisan kedua (9, 1).

c. *Concatenate* dan *fully connected layer*

Concatenate menggabungkan output dari kedua *branch* menjadi satu tensor, yang kemudian diteruskan ke lapisan pertama dari *fully connected layer* yang memiliki 128 neuron dengan fungsi aktivasi ReLU (activation='relu'). Lapisan *dropout* setelah lapisan *dense* pertama dengan rate 0.2. membantu mencegah *overfitting* dengan secara acak mematikan beberapa neuron selama pelatihan (Lampiran 4). Lapisan *dense* kedua memiliki satu neuron menggunakan aktivasi sigmoid (activation='sigmoid') sebagai lapisan output yang menghasilkan probabilitas bahwa input termasuk dalam kelas tertentu (imunogenisitas peptida).

3.5.4 Model Inference




Gambar 6: Computing dan kalkulasi Nilai Imuno

Model Inference memuat model CNN yang sudah dilatih sebelumnya (*weights*) dan menggunakan fungsi-fungsi sebelumnya (*construct_aaindex*, *pull_peptida_aaindex*, *pull_hla_aaindex*) untuk membuat input yang sesuai untuk model, kemudian model CNN yang dimuat digunakan untuk memprediksi skor imunogenisitas dari representasi numerik peptida dan HLA. Fungsi mengembalikan skor imunogenisitas

yang diprediksi oleh model CNN (Zhang dkk., 2018). Nilai ini adalah angka *floating-point* antara 0 dan 1, di mana nilai yang lebih tinggi menunjukkan probabilitas lebih tinggi bahwa peptida bersifat imunogenik. Pasangan peptida-HLA diunggah oleh fungsi *file_process* dan hasil prediksi disimpan dalam file baru.

3.5.5 Training dan Validasi Model



Gambar 7: Pelatihan dan Validasi Dataset

10-fold cross-validation adalah metode yang umum digunakan untuk mengevaluasi kinerja model, termasuk *Convolutional Neural Network* (CNN) dalam menganalisis efektivitasnya (Malakouti dkk., 2023). Proses dimulai dengan membagi dataset menjadi 10 subset atau “*fold*” dengan ukuran yang seimbang. Setiap iterasi melibatkan penggunaan 9 subset sebagai *training* dataset dan 1 subset sebagai data validasi yang dilakukan secara repetitif hingga mencapai akurasi yang sesuai dengan data validasi.

3.5.6 Implementasi dan Eksekusi Algoritma *Convolutional Neural Network* (CNN)

```

!python 'Imunogenisitas.py'
--mode "multiple" --indir "Data-immuno (1).csv"
--outdir "/content/drive/MyDrive/colab-deepimmuno/Epochfile"
  
```


Gambar 8: Eksekusi file *Python*

Versi *library* yang digunakan adalah: Pandas 2.1.4, NumPy 1.26.4, *TensorFlow* 2.8.0, dan *Keras* 2.8.0. *Library Pandas* berfungsi untuk mengelola data kompleks, *NumPy* mendukung komputasi numerik,

TensorFlow digunakan untuk struktur *machine learning* dan *deep learning*, sementara *keras* mempermudah pembangunan model *neural network*. Terdapat dua mode eksekusi yang dapat digunakan, yaitu “*single*” dan “*multiple*”. Mode *single* hanya dapat menjalankan *query* dengan satu pasang peptida dan alel HLA, sedangkan mode *multiple* memungkinkan eksekusi berulang dari proses pelatihan dan evaluasi sesuai dengan jumlah set data yang disediakan dengan cara memanfaatkan *input directory* sebagai lokasi file dataset dan *output directory* sebagai lokasi output skor imunogenisitas.

3.5.7 Visualisasi dan Analisis Data

Skor imunogenisitas yang telah dihasilkan akan dianalisis untuk mengevaluasi performa model. Skor-skor tersebut akan dipetakan dalam berbagai grafik, seperti kurva ROC, *precision-recall*, dan distribusi nilai prediksi, untuk mempermudah interpretasi kinerja model.



Gambar 9: Proses Analisis Data Imunogenisitas

Analisis nilai imunogenisitas dilakukan menggunakan pustaka *Python* seperti *Matplotlib*, *Seaborn*, dan *scikit-learn* (sklearn). *Matplotlib* digunakan untuk visualisasi dasar. *Seaborn* digunakan untuk visualisasi yang lebih kompleks, seperti KDE plot, untuk menggambarkan pola distribusi secara lebih detail. *Scikit-learn* diterapkan untuk menghitung metrik yang memberikan penilaian kuantitatif terhadap performa model CNN (Rashdi dkk., 2021).

3.6 Proses Analisis Data

3.6.1 Metrik Evaluasi Kerja

Metrik evaluasi kinerja adalah pengukuran kuantitatif yang bertujuan untuk mengevaluasi efektivitas kinerja model pada kumpulan data pengujian dalam mencapai tujuan yang ditetapkan. Penentuan baik atau tidaknya model prediksi didasarkan dari parameter pengukuran performa. Penelitian

ini menggunakan lima metrik kerja yaitu: akurasi, presisi, *recall*, spesifisitas, dan *f1-score*. Dalam memvisualisasikan dan merangkum performa algoritma klasifikasi, digunakan tabel *confusion matrix* yaitu tabel yang menyatakan klasifikasi jumlah data uji yang benar dan jumlah data uji yang salah (Normawati dan Prayogi, 2021).

Tabel 3: Elemen *Confusion Matrix*

Nilai Prediksi Imunogenitas		
Nilai Aktual Imunogenitas	Positif Benar (TP)	Positif Salah (FP)
	Negatif Salah (FN)	Negatif Benar (TN)

3.6.1.2 Akurasi

Akurasi didefinisikan sebagai rasio antara jumlah prediksi yang benar dengan total jumlah prediksi yang dilakukan oleh model untuk mengukur seberapa akurat model klasifikasi dalam memprediksi kelas dari data uji. Berikut merupakan rumus akurasi model:

$$\text{Akurasi} = \frac{TP+TN}{TP+FP+FN+TN}$$

3.6.1.3 Presisi dan Spesifisitas

Presisi adalah metrik yang digunakan untuk mengevaluasi proporsi antara prediksi positif yang benar dan himpunan semua nilai positif sebenarnya. Sedangkan, spesifisitas bertujuan untuk mengukur kemampuan model dalam memprediksi kasus negatif. Berikut merupakan rumus presisi dan spesifisitas:

$$\text{Presisi} = \frac{TP}{TP+FP} \quad \text{Spesifisitas} = \frac{TN}{TN+FP}$$

3.6.1.4 Recall

Recall adalah metrik evaluasi yang mengukur kemampuan model secara khusus mengenai proporsi antara jumlah positif yang berhasil ditemukan oleh model (*true positive*) dengan total jumlah *instance* positif yang sebenarnya dalam dataset. Berikut merupakan rumus *recall* model:

$$\text{Recall} = \frac{TP}{TP+FN}$$

3.6.1.5 F1-Score

F1-Score adalah metrik evaluasi yang menggabungkan presisi dan *recall* untuk memberikan gambaran yang lebih holistik tentang kinerja model klasifikasi. *F-1 score* dihitung dengan mengambil nilai *mean* dari presisi dan *recall*. Berikut merupakan rumus *F-1 score* model:

$$\text{F-1 Score} = \frac{2 \times \text{Presisi} \times \text{Recall}}{\text{Presisi} + \text{Recall}}$$

3.6.1.6 Kurva ROC dan Precision-Recall

Kurva ROC-AUC dibuat berdasarkan nilai yang telah didapatkan dari perhitungan dengan *confusion matrix*, yaitu antara *false positive Rate* dengan *true positive rate*. Pada *confusion matrix*, performa informasi hanya disajikan dalam bentuk angka. Sehingga untuk menampilkan informasi kinerja algoritma klasifikasi dalam bentuk grafik dapat digunakan Receiver Operating Characteristic (ROC) atau kurva *precision-recall*. Kurva ROC digunakan untuk membandingkan nilai kinerja masing-masing algoritma dapat dilakukan dengan membandingkan luas di bawah kurva atau AUC (*Area Under Curve*) (Kristiawan dan Widjaja, 2021).

3.7 Analisis Varian Alel HLA (*Human Leukocyte Antigen*)

Penilaian imunogenisitas sel-T memerlukan evaluasi ketergantungan alel MHC pada preferensi asam amino tertentu. Dilakukan pengumpulan semua peptida imunogenik yang terikat dengan setiap alel. Penggunaan beragam varian alel HLA pada model menghasilkan output nilai prediksi yang berbeda, skor tertinggi kemudian diidentifikasi sebagai alel yang paling optimal dalam mengikat peptida. Penelitian ini menggunakan 4 alel yaitu: 1) HLA-A*0201, 2) HLA-A*2402, 3) HLA-B*0702, 4) HLA-C*0701. Pemilihan alel didasarkan pada kajian literatur yang mengidentifikasi alel-alel ini sebagai relevan berikatan dengan peptida kanker paru.

BAB 4. HASIL DAN PEMBAHASAN

4.1 Hasil

4.1.1 Modifikasi Arsitektur *Convolutional Neural Network* (CNN)

Hasil modifikasi arsitektur CNN terdiri dari 2 *input layer*, 3 *convolutional layer*, 3 *batch normalization layer*, 3 *activation layer*, 2 *maxpooling layer*, 2 *flatten layer*, 1 *concatenate layer*, 2 *fully connected layer*, dan 1 *dropout layer* (Gambar 10). Peneliti memodifikasi model menggunakan lapisan konvolusional dua dimensi (*Conv2D*).


Layer (type)	Output Shape	Param #	Connected to
input_layer_1 (InputLayer)	(None, 46, 12, 1)	0	-
input_layer (InputLayer)	(None, 10, 12, 1)	0	-
conv2d_2 (Conv2D)	(None, 32, 1, 16)	2,896	input_layer_1[0][0]
conv2d (Conv2D)	(None, 9, 1, 16)	400	input_layer[0][0]
batch_normalization_2 (BatchNormalization)	(None, 32, 1, 16)	64	conv2d_2[0][0]
batch_normalization (BatchNormalization)	(None, 9, 1, 16)	64	conv2d[0][0]
re_lu_2 (ReLU)	(None, 32, 1, 16)	0	batch_normalization_2[0][0]
re_lu (ReLU)	(None, 9, 1, 16)	0	batch_normalization[0][0]
max_pooling2d_1 (MaxPooling2D)	(None, 16, 1, 16)	0	re_lu_2[0][0]
conv2d_1 (Conv2D)	(None, 8, 1, 32)	1,056	re_lu[0][0]
conv2d_3 (Conv2D)	(None, 8, 1, 32)	4,640	max_pooling2d_1[0][0]
batch_normalization_1 (BatchNormalization)	(None, 8, 1, 32)	128	conv2d_1[0][0]
batch_normalization_3 (BatchNormalization)	(None, 8, 1, 32)	128	conv2d_3[0][0]
re_lu_1 (ReLU)	(None, 8, 1, 32)	0	batch_normalization_1[0][0]
re_lu_3 (ReLU)	(None, 8, 1, 32)	0	batch_normalization_3[0][0]
max_pooling2d (MaxPooling2D)	(None, 4, 1, 32)	0	re_lu_1[0][0]
max_pooling2d_2 (MaxPooling2D)	(None, 4, 1, 32)	0	re_lu_3[0][0]
flatten (Flatten)	(None, 128)	0	max_pooling2d[0][0]
flatten_1 (Flatten)	(None, 128)	0	max_pooling2d_2[0][0]
concatenate (Concatenate)	(None, 256)	0	flatten[0][0], flatten_1[0][0]
dense (Dense)	(None, 128)	32,896	concatenate[0][0]
dropout (Dropout)	(None, 128)	0	dense[0][0]
dense_1 (Dense)	(None, 1)	129	dropout[0][0]

Total params: 42,401 (165.63 KB)
Trainable params: 42,209 (164.88 KB)
Non-trainable params: 192 (768.00 B)

Gambar 10: Pemodelan Arsitektur *Convolutional Neural Network* (CNN)

4.1.2 Hasil Performa Model

4.1.2.1 Hasil Confusion Matrics



Gambar 11: Hasil *Confusion Matrics*


Gambar 11 menunjukkan *confusion matrices* dari model *deep learning* yang dibuat. Hasil prediksi didapatkan *true negative* (TN) sejumlah 166 data, *true positive* (TP) sejumlah 304 data, *false positive* (FP) sejumlah 25 data, dan *false negative* (FN) sejumlah 4 data. Berdasarkan hasil *confusion matrices* didapatkan nilai akurasi sebesar 94%, presisi sebesar 92%, spesifisitas sebesar 86%, *recall* sebesar 98%, dan *f-1 score* sebesar 95% (Tabel 4).

Tabel 4: Hasil Skor Akhir *Confusion Matrics*


Akurasi	0,94
Presisi	0,92
Spesifisitas	0,86
<i>Recall</i>	0,98
<i>F-1 Score</i>	0,95

4.1.2.2 Kurva *Precision-Recall* dan ROC-AUC Logistic

Hasil prediksi model menghasilkan prediksi yang stabil yaitu pada gambar 12 kurva ROC dan kurva *precision-recall* hanya dari model prediksi pada validasi 10-*fold* dari dataset pelatihan IEDB. Di sini, 0.5 digunakan sebagai ambang batas untuk membedakan antara *instance* positif dan negatif. Hasil kurva ROC pada *fold* ke-10 sebesar 0,9 yang mengindikasikan bahwa model memiliki nilai diskriminasi yang hampir sempurna dan kurva *precision-recall* didapatkan sebesar 0,74.



Gambar 12: Grafik Kurva *Precision-Recall* dan ROC




Gambar 13: Grafik akurasi, presisi, *recall*, *f-1 score*, dan spesifisitas setiap *fold*

4.1.3 Perbandingan Model Prediksi Imunogenisitas

Hasil menunjukkan bahwa perbandingan model prediksi imunogenitas dari penelitian terdahulu didapatkan bahwa model peneliti menunjukkan hasil skor tertinggi berdasarkan kurva ROC (Gambar 14).


Perbandingan Model Prediksi Peptida Imunogenik Berdasarkan Nilai Kurva ROC-AUC




Gambar 14: Grafik Perbandingan Model Prediksi Peptida Imunogenik

4.1.4 Analisis Varian HLA

Gambar 15 menunjukkan hasil analisis varian HLA dari keempat alel. Berdasarkan hasil tersebut didapatkan bahwa alel HLA*0701 merupakan alel dengan kemampuan pengikatan terbaik (Gambar 16).



Gambar 15: Skor Variasi HLA



Gambar 16: HLA C*0701

4.2 Pembahasan

Penelitian ini menggunakan metode *convolutional neural network* dengan objektif memprediksi peptida imunogenik yang berpotensi untuk digunakan pada vaksin dan imunoterapi. Prediksi ini melibatkan modifikasi arsitektur yang dirancang untuk mengidentifikasi peptida imunogenik secara efisien. Modifikasi arsitektur terdiri dari dua *input layer*, tiga *convolutional layer*, tiga *batch normalization layer*, tiga *activation layer*, dua *maxpooling layer*, dua *flatten layer*, satu *concatenate layer*, dua *fully connected layer*, dan satu *dropout layer*. Data input berupa sekuens peptida yang akan diekstraksi fitur pentingnya pada setiap lapisan *convolutional layer*. CNN memanfaatkan lapisan konvolusi untuk mengekstrak fitur dari data input. Dalam hal ini, pola yang relevan bisa berupa motif atau struktur yang berpotensi menunjukkan sifat imunogenik. Setiap mendeteksi pola penting dalam peptida yang relevan untuk imunogenisitas. Peneliti menggunakan tiga lapisan konvolusi ini untuk mengekstraksi fitur yang lebih kompleks di tiap tahap. Lapisan *batch* digunakan untuk menormalisasi output dari lapisan sebelumnya menjadi standar deviasi satu. Setiap lapisan konvolusi diikuti oleh fungsi aktivasi ReLU. Pooling layer yang digunakan menggunakan operasi max pooling yang berfokus pada informasi esensial dan mengurangi risiko *overfitting*. Dimana sebelum masuk pada fully connected layer harus dilakukan flatten terlebih dahulu yaitu mengubah bentuk multidimensi array menjadi vektor (Lestandy, 2022). *Concatenate layer* digunakan untuk menggabungkan berbagai informasi fitur yang diproses oleh jaringan sehingga analisis imunogenisitas peptida menjadi lebih kaya dan mendalam. Lapisan *fully connected (dense layer)* bertanggung jawab untuk melakukan klasifikasi berdasarkan fitur yang telah diekstraksi oleh jaringan sebelumnya. Setiap neuron di lapisan ini terhubung dengan setiap neuron di lapisan sebelumnya untuk memprediksi akhir mengenai imunogenisitas peptida. Pada akhir arsitektur, dropout layer akan menonaktifkan neuron selama proses pelatihan untuk mencegah *overfitting*. Modifikasi pada penelitian ini yaitu penggunaan *Conv2D* yang memberikan keunggulan dalam analisis data urutan dengan mengekstraksi pola spasial yang lebih kompleks di kedua dimensi, yakni waktu dan fitur. *Conv2D* efektif dalam mengidentifikasi pola lokal di sepanjang kedua dimensi pada data *multi-channel* yaitu urutan sekuens peptida. Selain itu, *Conv2D* mampu menangkap interaksi yang lebih kompleks dibandingkan *Conv1D*, yang hanya bergerak dalam satu dimensi, sehingga memungkinkan eksplorasi pola yang lebih mendalam dan fleksibel dalam memprediksi pengikatan dengan alel.

Berdasarkan hasil *confusion matrix* yang telah diuji dengan metode CNN mendapatkan nilai akurasi yang cukup tinggi yaitu sebesar 94%. Penelitian kami menggunakan 10 *epochs* untuk mencapai tingkat akurasi 94%. Pada penelitian ini kami mempertimbangkan akurasi sebagai kriteria utama karena jauh lebih tinggi jumlah peptida imunogenik positif versus negatif yang diamati (tidak seimbang). Untuk evaluasi awal, kami menggunakan validasi silang 10 kali lipat untuk menilai efektivitas model arsitektur CNN. Model mendapatkan nilai recall yang sangat tinggi yaitu sebesar 98% menunjukkan bahwa model

berhasil memprediksi 98% dari semua peptida yang benar-benar imunogenik (positif) dalam dataset dengan benar. Sedangkan di lain sisi, model mendapatkan nilai spesifisitas sebesar 86% menunjukkan bahwa model dapat mengidentifikasi dengan benar 86% dari semua peptida yang benar-benar negatif (tidak imunogenik). Maka dari itu, dapat dikatakan bahwa model kami memiliki performa yang lebih baik untuk memprediksi peptida yang imunogenik dibandingkan tidak imunogenik. Hal ini juga sesuai dengan hasil *f-1 score* model yaitu sebesar 95% dengan keseimbangan antara precision dan recall karena model memprediksi kelas positif dengan memperhitungkan *false positives* dan *false negatives* secara akurat. Di dalam setiap putaran, area di bawah kurva karakteristik operasi penerima (auROC) dihitung untuk membandingkan kinerja model pada beberapa *fold* yang berbeda. Berdasarkan grafik ROC-AUC menunjukkan bahwa pada fold terakhir didapatkan hasil sebesar 0,90 yang menunjukkan bahwa performa model secara keseluruhan bekerja dengan baik.

Dalam mengevaluasi keefektifan model yang dibuat, peneliti membandingkan hasil skor ROC model dengan model prediksi peptida imunogenik lain khususnya yang berfokus pada pengikatan dengan MHC kelas I. Hasil menunjukkan bahwa model peneliti memiliki hasil yang sangat baik dalam memprediksi dengan rata-rata ROC 0,9. Net Tepi menunjukkan hasil yang mendekati sebesar 0,8 dengan skor presentase sensitivitas (*recall*) sebesar 90%. Dalam menghitung prediksi peptida untuk kanker paru, *recall* menjadi matriks yang penting karena terutama dalam penyakit yang agresif seperti kanker paru, prioritasnya adalah memastikan bahwa peptida yang dapat memicu respons imun (imunogenik) terdeteksi secara maksimal (Roudko dkk. 2020). Maka dari itu, model peneliti memiliki nilai recall sebesar 0,98 yang berarti model bekerja lebih efektif dalam memprediksi peptida imunogenik khususnya pada penyakit kanker paru. Penelitian yang diadakan oleh Trevizani dan Custodio pada tahun 2022 juga menggunakan algoritma *convolutional neural network* (CNN) menunjukkan hasil yang lebih rendah sebesar 0,6. Sedangkan model Deep TCr memiliki nilai ROC sebesar 0,88 dengan menggunakan dataset COVID-19. Hal ini menunjukkan bahwa model peneliti memiliki rata-rata nilai ROC yang relatif lebih tinggi dibandingkan model prediksi lainnya. Peningkatan akurasi hasil disebabkan oleh kemampuan model dalam memahami pola-pola pengikatan spesifik pada kanker paru, sehingga menghasilkan prediksi yang lebih akurat. Selain itu, tidak ada peptida yang dapat menjadi peptida sel-T tanpa terlebih dahulu terikat dan dipresentasikan oleh molekul MHC-I. Oleh karena itu, penyeleksian pada pengumpulan data afinitas pengikatan MHC menyebabkan metode prediksi afinitas pengikatan MHC memiliki kinerja prediksi tertinggi untuk peptida sel-T.

Dalam menilai aturan yang mengatur imunogenisitas sel-T pada alel HLA yang berbeda, peneliti mengevaluasi ketergantungan alel MHC pada preferensi asam amino spesifik. Dalam melakukan analisis ini, peneliti mengumpulkan semua peptida imunogenik yang terikat pada setiap alel dan menghasilkan matriks motif berdasarkan bobot pentingnya posisi yang disimpulkan dalam model. Hasil menunjukkan bahwa alel HLA-C*0701 dan HLA-A*0201 menghasilkan skor peptida imunogenik yang cenderung lebih tinggi. Hal ini sesuai dengan penelitian yang dilakukan oleh Schaafsma (2021) bahwa perubahan dalam ekspresi HLA-C dapat memengaruhi respons tumor terhadap terapi berbasis imun. Selain itu yang dikatakan oleh Holasch (2023) bahwa HLA-A*0201 memiliki kemampuan untuk mempresentasikan antigen yang terkait dengan tumor sehingga memungkinkan sistem kekebalan tubuh mengenali dan menyerang sel kanker dengan lebih efektif.

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

5.1.1 Penelitian ini berhasil memodifikasi arsitektur *convolutional neural network (CNN)* dengan mengimplementasikan lapisan dua dimensi (conv2D) untuk meningkatkan keakuratan model dalam mempelajari pola spesifik untuk memprediksi peptida imunogenik pada kanker paru khususnya. Selain itu peneliti berhasil memodifikasi keseluruhan layer model yang terdiri dari 2 *input layer*, 3 *convolutional layer*, 3 *batch normalization layer*, 3 *activation layer*, 2 *maxpooling layer*, 2 *flatten layer*, *concatenate layer*, 2 *fully connected layer*, dan 1 *dropout layer* menu. Modifikasi arsitektur ini bekerja dengan baik ditunjukkan dari hasil performa model.

5.1.2 Berdasarkan confusion matrix menunjukkan hasil nilai akurasi sebesar 94%, presisi sebesar 92%, spesifisitas sebesar 86%, *recall* sebesar 98%, dan *f-1 score* sebesar 95%. Kurva ROC-AUC didapatkan 0,9 sehingga dapat disimpulkan bahwa model peneliti secara keseluruhan memiliki kinerja yang sangat baik dalam memprediksi peptida imunogenik pada kanker paru.

5.1.3 Berdasarkan perbandingan model prediksi lainnya, model peneliti menunjukkan hasil kurva AUC tertinggi yaitu sebesar 0,9 menunjukkan bahwa kemampuan model dalam memprediksi peptida yang imunogenik memiliki performa yang lebih akurat.

5.1.4 Dari empat varian alel (HLA-A*0201, HLA-A*2402, HLA-B*0702, HLA-C*0701) didapatkan bahwa alel HLA-C*0701 dan HLA*0201 merupakan alel terbaik untuk mengikat epitop imunogenik pada kanker paru. Kedua alel ini terbukti memiliki kemampuan mempresentasikan antigen yang baik dan prevalansi yang tinggi.

5.2 Saran

5.2.1 Saran Bagi Pemerintah

Pemerintah diharapkan mampu bekerja sama untuk mengembangkan metode memprediksi peptida imunogenik dengan memanfaatkan kecerdasan buatan sehingga alat ini dapat dipergunakan untuk memprediksi peptida imunogenik pada penyakit lain di Indonesia. Selain itu, penting juga bagi pemerintah untuk mendukung pendanaan riset dan pengembangan teknologi ini agar bisa diimplementasikan secara luas di sektor kesehatan, termasuk untuk mengembangkan *targeted-immunotherapy* dan *targeted vaccine*.

5.2.2 Saran Bagi Masyarakat

Masyarakat diharapkan untuk lebih memahami pentingnya penelitian di bidang imunologi dan kecerdasan buatan, khususnya dalam memprediksi peptida imunogenik yang berperan dalam respons imun terhadap penyakit. Selain itu, masyarakat juga diimbau untuk mendukung upaya pemerintah dalam pengembangan teknologi ini guna berkontribusi pada pencegahan dan pengobatan penyakit secara lebih efektif di Indonesia.

5.2.2 Saran Bagi Peneliti

Saran untuk penelitian selanjutnya untuk menggunakan jumlah sampel yang lebih banyak sehingga mampu menghasilkan prediksi yang baik karena CNN bergantung dengan jumlah input data untuk dapat menghasilkan performa terbaik. Pengumpulan data lebih banyak dari berbagai seperti database global peptida imunogenik serta data klinis dari berbagai jenis penyakit. Hal ini dapat membuka peluang untuk mengembangkan model prediksi yang lebih handal dan dapat digunakan untuk berbagai aplikasi, seperti vaksin kanker atau pengobatan berbasis imunoterapi.

UCAPAN TERIMA KASIH

Kami ingin memuji dan mengucapkan syukur kepada Tuhan Yang Maha Esa atas rahmat dan karunia serta bimbingan-Nya sepanjang seluruh proses penelitian ini. Penyelesaian penelitian ini yang berjudul “Prediksi Peptida Imunogenik untuk Imunitas Sel-T sebagai Epitop Potensial *Targeted-Vaccine* dan *Targeted-Immunotherapy* pada Kanker Paru Berbasis *Deep Learning* Menggunakan Algoritma *Convolutional Neural Network* (CNN)” tidak akan terjadi tanpa kontribusi semua pihak-pihak yang ikhlas memberikan dukungan moral dan juga dukungan materi kepada kami. Kami ingin mengungkapkannya terima kasih kami yang sebesar besarnya kepada:

1. Bapak I Made Sudana, S.Pd., M.Pd, selaku kepala sekolah yang memberi kami kesempatan untuk mengikuti ajang ini dan memfasilitasi tempat pelaksanaan penelitian kami.
2. Ibu Ni Made Margiani, S.E., S.Pd., sebagai pembimbing penelitian kami yang bersedia untuk membantu dan memberikan saran selama berjalannya penelitian kami.
3. Michael Gitonobel, selaku ahli sains yang telah bersedia menyediakan waktu di tengah kesibukan kuliahnya untuk berbagi ilmu serta memberikan saran dan kritik terkait ide penelitian kami.
4. Keluarga kami yang senantiasa menunjukkan keistimewaannya, cinta, perhatian, dan dorongan kepada kami untuk menyelesaikan penelitian ini.

Kami menyadari bahwa penelitian ini masih memerlukan banyak perbaikan dari segi konten dan penulisan. Oleh karena itu, kami mengharapkan kritik dan saran untuk membantu kami dalam mengembangkan penelitian ini. Kami berharap ini penelitian dapat bermanfaat bagi pembaca dan peneliti lain.

DAFTAR PUSTAKA

- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Farhan, L. (2021). Review of Deep Learning: Concepts, CNN Architectures, challenges, applications, Future Directions. *Journal of Big Data*, 8(1). DOI:10.1186/s40537-021-00444-8.
- Andayani N., Julisafrida, L. 2020. Peranan Immunoterapi Pada Kanker Paru. *Jurnal Kedokteran Syiah Kuala*, 20(2). DOI:10.24815/jks.v20i2.18499.
- Buana I., Harahap D. A. 2022. Asbestos, Radon Dan Polusi Udara Sebagai Faktor Resiko Kanker Paru Pada Perempuan Bukan Perokok. *AVERROUS: Jurnal Kedokteran Dan Kesehatan Malikussaleh*: 8(1), 1. DOI:10.29103/averrous.v8i1.7088.
- Direktorat Jenderal Pencegahan dan Pengendalian Penyakit. 2018. Pedoman pengendalian risiko kanker paru. 6-14. Jakarta: Kementerian Kesehatan Republik Indonesia.
- Gandon, S., & Lion, S. 2022. Targeted vaccination and the speed of SARS-COV-2 adaptation. *Proceedings of the National Academy of Sciences*, 119(3). DOI:10.1073/pnas.2110666119.
- Garcia A. A., Plain K. M., Thomson P. C., Thomas A. J., Davies C. J., Toribio J., Whittington R. J. 2023. Association between major histocompatibility complex haplotypes and susceptibility of unvaccinated and vaccinated cattle to paratuberculosis. *Veterinary Immunology and Immunopathology*, 265, 110677. DOI: 10.1016/j.vetimm.2023.110677.
- Gupta J., Pathak S., Kumar G. 2022. Deep learning (CNN) and Transfer learning: A review. *Journal of Physics: Conference Series*, 2273(1), 012029. DOI:10.1088/1742-6596/2273/1/012029.
- Hao, Q., Wei P., Shu Y., Zhang Y., Xu H., Zhao J. 2021. Improvement of Neoantigen identification through Convolution Neural Network. *Frontiers in Immunology* 12. DOI: 10.3389/fimmu.2021.682103.
- Hermawati F. A., Safii M.I. 2021. Sistem Deteksi Keganasan Kanker Paru-Paru pada CT-Scan dengan Menggunakan Metode Mask Region-based Convolutional Neural Network (Mask R-CNN). *Proceeding KONIK (Konferensi Nasional Ilmu Komputer)* 5(1): 193-197. <https://prosiding.konik.id/index.php/konik/article/view/49> [5 Maret 2024].
- Hollasch M. 2023. OSE2101 Cancer Vaccine Yields Favorable OS vs SOC in HLA-A*02+ ICI-Resistant NSCLC. <https://www.onclive.com/view/ose2101-cancer-vaccine-yields-favorable-os-vs-soc-in-hla-a-02-ici-resistant-nsclc> [25 Agustus 2024]
- International Agency for Research Cancer. 2014. Date Word of Cancer. <http://gco.iarc.fr/>.
- Joglekar A. V., Li G. 2020. T cell antigen discovery. *Nature Methods*: 18(8), 873–880. DOI: 10.1038/s41592-020-0867-z.
- Kondororik F., Martosupono M., Susanto A. B. 2017. Peranan β -karotendalam Sistem Imun untuk Mencegah Kanker. *Jurnal Biologi & Pembelajarannya* 4(1) :1-8.
- Lefranc M., Giudicelli V., Ginestoux C., Jabado J., Folch G., Bellahcene F., Wu Y., Gemrot E., Brochet X., Lane J., Regnier L., Ehrenmann F., Lefranc G., Duroux P. 2015. IMGT: International Immunogenetics Information System. DOI: 10.1093/nar/gkn838
- Lestandy M. 2022. Deteksi Dini Kanker Payudara Menggunakan metode convolution neural network (CNN). *Jurnal Teknologi Informasi dan Komunikasi* 12(1):65. DOI:10.35585/inspir.v12i1.2667.
- Li G., Iyer B., Prasath V. B., Ni Y., Salomonis N. 2021. DeepImmuno: Deep learning-empowered prediction and generation of immunogenic peptides for T-cell immunity. *Briefings in Bioinformatics*: 22(6). DOI:10.1093/bib/bbab160.
- Lisa A., Urry, Micheal L., Cain., Steven A., Wasserman., Peter V. M. 2020. [Campbell Biology Series] in - Campbell Biology, 12th Edition. N. Pierson. Boston.
- Malakouti S. M., Menhaj M. B., Suratgar A. A. 2023. The usage of 10-fold cross-validation and grid search to enhance ML methods performance in Solar Farm Power Generation Prediction. *Cleaner Engineering and Technology*:15, 100664. DOI: 10.1016/j.clet.2023.100664.

- Mandasari A. A. 2015. Analisis Epitop Sel-B dan Sel-T Pada Protein prM/E Virus Dengue [Tesis]. Yogyakarta: Fakultas Biologi, Universitas Gadjah Mada.
- Nandhini A. R., Durai R. V. P. M., Srinivasan, K., Tariq U., Chang C. Y. 2021. *Deep CNN and deep gan in computational visual perception-driven image analysis*. *Complexity*: 30. DOI:10.1155/2021/5541134.
- Normawati D., Prayogi S. A. 2021. Implementasi Naïve Bayes Classifier Dan Confusion Matrix Pada Analisis Sentimen Berbasis Teks Pada Twitter. *J-SAKTI* 5(2): 697-711. DOI: <http://dx.doi.org/10.30645/j-sakti.v5i2.369>.
- Ogishi M., Yotsuyanagi H. 2019. *Quantitative Prediction of the Landscape of T-cell Epitope Immunogenicity in Sequence Space*. *Frontiers in Immunology*: 10. DOI:10.3389/fimmu.2019.00827.
- Oluwasakin E., Torku, T., Tingting S., Yinusa, A., Hamdan, S., Poudel S., Poudel K. (2023). Minimization of high computational cost in data preprocessing and modeling using MPI4Py. *Machine Learning with Applications*, 13, 100483. DOI:10.1016/j.mlwa.2023.100483.
- Rahman M. M., Masum M. H., Talukder A., Akter R. 2023. *An in silico reverse vaccinology approach to design a novel multiepitope peptide vaccine for non-small cell lung cancers*. *Informatics in Medicine Unlocked*: 37, 101169. DOI: 10.1016/j.imu.2023.101169.
- Roudko V., Greenbaum B., Bhardwaj N. 2020. *Computational Prediction and Validation of Tumor-Associated Neoantigens*. *Front Immunol* 11(4): 27. DOI: 10.3389/fimmu.2020.00027.
- Saraswati H. 2021. Pengenalan Antigen Oleh Respon Imun. [Skripsi]. Jakarta: Fakultas Kedokteran, Universitas Esa Unggul.
- Schaafsma E., Fugle C., Wang X., Cheng C. 2021. *Pan-cancer association of HLA gene expression with cancer prognosis and immunotherapy efficacy*. *Br J Cancer* 125(3):422-432. DOI: 10.1038/s41416-021-01400-2.
- Schmidt J., Smith A. R., Magnin M., Racle J., Devlin J. R., Bobisse S., Gfeller D. 2021. *Prediction of neo-epitope immunogenicity reveals TCR Recognition Determinants and provides insight into immunoediting*. *Cell Reports Medicine*: 2(2), 100194. DOI: 10.1016/j.xcrm.2021.100194.
- Ser Z., Gu Y., Yap J., Lim Y. T., Wang S. M., Hamidin M., Sobota R. M. 2023. *Hybrid structural modeling of alloantibody binding to human leukocyte antigen with rapid and reproducible cross-linking mass spectrometry*. *Cell Reports Methods*: 3(9), 100569. DOI: 10.1016/j.crmeth.2023.100569.
- Sidhom J., Larman H., Baras A. 2018. *DeepTCR: A deep learning framework for understanding T-cell receptor sequence signatures within complex T-cell repertoires*. DOI: 10.1101/464107.
- Smith J. A., Johnson R. B. 2020. *Targeted Therapy in Immunotherapy: A Review of Recent Advances*. *Journal of Immunotherapy*: 15(3), 112-125. DOI: 10.1002/jimmun.20200045.
- Thandra, C. K., Barsouk A., Saginala K., Sukumar A. J. 2021. *Epidemiology of Lung Cancer*. *Współczesna Onkologia* 25(1): 45–52. DOI:10.5114/wo.2021.103829.
- Trevizani R., Custódio F. (2022). *Deepitope: Prediction of HLA-independent T-cell epitopes mediated by MHC class II using a convolutional neural network*. *Jurnal Artificial Intelligence in the Life Sciences* 2: 100038. DOI: 10.1016/j.aailsci.2022.100038.
- Trolle T., Nielsen M. 2014. *NetTepi: An integrated method for the prediction of T cell epitopes*. *Immunogenetics*: 66(7–8), 449–456. DOI:10.1007/s00251-014-0779-0.
- Wulandari L., Faot N. E. 2019. Problem Penegakkan diagnostik Pasien Dengan Massa di Paru. *Jurnal Respirasi*: 3(2), 41. DOI:10.20473/jr.v3-i.2.2017.41-46.
- Yuan Y., Hou S., Wu X., Wang Y., Sun Y., Yang Z., Zhang F. 2024. *Application of deep-learning to the automatic segmentation and classification of lateral lymph nodes on ultrasound images of papillary thyroid carcinoma*. *Asian Journal of Surgery*. DOI: 10.1016/j.asjsur.2024.02.140.

LAMPIRAN

Lampiran 1: *Timeline Kegiatan Penelitian*

No	Kegiatan	Tahun 2024						
		Februari	Maret	April	Mei	Juni	Agustus	September
1.	Observasi							
2.	Penyusunan proposal							
3.	Pengumpulan data set							
4.	Pembuatan model <i>deep learning</i>							
5.	Pengujian model <i>deep learning</i>							
6.	Penyusunan laporan penelitian							
7.	Revisi laporan penelitian							

Lampiran 2: Rincian Kegiatan Penelitian

No	Waktu	Tempat	Kegiatan
1	3 Februari 2024	Rumah peneliti	Penemuan dan analisis masalah
	10 Februari 2024	Rumah peneliti	Konsultasi Ide Penelitian
2	11 Februari 2024	Rumah peneliti	Perancangan konsep model
3	18 Februari 2024	Rumah peneliti	Perancangan kerangka penelitian
4	24 Februari 2024	Rumah peneliti	Analisis Teoritis dan Tinjauan Pustaka
5	1 Maret 2024	<i>Online</i>	Supervisi dan Konseling Penelitian
6	2 Maret 2024	SMAN 4 Denpasar	Perincian data dan instrument penelitian
7	5 Maret 2024	Rumah peneliti	Penyusunan proposal
8	13 Maret 2024	SMAN 4 Denpasar	Revisi dan evaluasi proposal
9	15 Maret 2024	Rumah Peneliti	Pengumpulan naskah proposal penelitian
10	18 April 2024	Rumah peneliti	Perbaikan naskah sesuai dengan revidi juri
11	24 Mei 2024	Rumah peneliti	Konsultasi Naskah Penelitian
12	30 Mei 2024	Lab Komputer SMAN 4 Denpasar	Pengambilan Data Set
13	10 Juni 2024	Lab Komputer SMAN 4 Denpasar	Pembuatan Model <i>Deep Learning</i>
14	5 Agustus 2024	Lab Komputer SMAN 4 Denpasar	Training dan validasi output model <i>deep learning</i>
15	6 Agustus 2024	Rumah Peneliti	Pembuatan laporan penelitian
16	1 September 2024	Rumah peneliti	Revisi naskah laporan penelitian

Lampiran 3: *Website IMGT 666 entries*

THANK YOU
for using [IMGT/3Dstructure-DB](#) and [IMGT/2Dstructure-DB](#)

THE
INTERNATIONAL
IMMUNOGENETICS
INFORMATION SYSTEM®



<http://www.imgt.org>

Entry code Search

IMGT/3Dstructure-DB card for 1a1m



IMGT molecule name	IMGT receptor type	IMGT receptor description	Ligand(s)	Species	CC	Chain ID
MIH1 ILA-D*5301	MIH1	MIH1 ALPHA D2M		/Homo sapiens (human)	1	[1a1m_A 1a1m_D]
		Peptide	Gag peptide P16 182-190 (P18095)	Human immunodeficiency virus 2	1	[1a1m_C]

Experimental technique X-ray diffraction Resolution (in angstroms) 2.3 Release date 08 APR 98

Chain details	Contact analysis	Paratope and epitope	3D visualization	Renumbered IMGT file	IMGT numbering comparison	References and links	Printable card
-------------------------------	----------------------------------	--------------------------------------	----------------------------------	--------------------------------------	---	--------------------------------------	--------------------------------

Chain details

For the IMGT Residue@Position card of a given residue, click on its letter in a sequence.
Differences with the closest IMGT allele sequence are in orange.

Chain details of MIH1 ILA-D*5301, MIH1, MIH1 ALPHA D2M Homo sapiens (human) [1a1m_A 1a1m_D]	
Chain ID	1a1m_A
Chain length	278
IMGT chain description	1 ALPHA = G-ALPHA1 (1-90) [D1] + G-ALPHA2 (91-182) [D2] + C-LIKE (183-274) [D3]
Chain sequence	G-ALPHA1 (1-90) [D1] [GSISRYFYTANSRPGSEPRFIAVGVSDGTQVVFSDASPRTEPPAIEGEPEYMDRITQTFKTNQTYREHLRIALRYNQSEA G-ALPHA2 (91-182) [D2] [GSILIQRYVGLDGPGLLRIGVDSAYDQDTIALILDLSSMTAAITAAQLTQPKLAARVALQIAYLGLGVLMIRRYLNGKLTQ C-LIKE (183-274) [D3] [SDPPKTHVTHPVSQHEATLRQNALGFPAETLTQRGGEQIQDTLVELTFPAQRTFQDAWVWVPSGEQRYTCWQHEGLPKPL]TI RUFFHH
Sequence in FASTA format Sequence in IMGT format	

Lampiran 4: Concatenate Layer

```
combined = layers.concatenate([x.output, y.output])
z = layers.Dense(128, activation='relu')(combined)
z = layers.Dropout(0.2)(z)
z = layers.Dense(1, activation='sigmoid')(z)
```

Lampiran 5: Klasifikasi hierarkhis (dictionary)

```
def dictionary(inventory):
    dicA, dicB, dicC = {}, {}, {}
    dic = {'A': dicA, 'B': dicB, 'C': dicC}
    for hla in inventory:
        type_ = hla[4]
        first2 = hla[6:8]
        last2 = hla[8:]
        try:
            dic[type_][first2].append(last2)
        except KeyError:
            dic[type_][first2] = []
            dic[type_][first2].append(last2)
    return dic
```

Lampiran 6: Link Github Repository

<https://github.com/Terano24/OPSI-Project>

Lampiran 7: Respon Reviu Juri

Reviu

Ide proposal prediksi peptide imunogenik menggunakan CNN cukup menarik. Skema penelitian serta pembuatan arsitektur CNN juga sudah di gambarkan dengan baik. Namun, dalam tahap pre-processing data belum dijelaskan apa saja yang dilakukan. Harap dilengkapi dengan lebih detail

Informasi Lainnya

Lolos Seleksi Berkas : Ya

Apakah proposal dapat lanjut ke proses penelitian ? : Ya

Poin hasil reviu proposal: Jelaskan lebih dalam mengenai tahap *pre-processing*.

Pada BAB 3 Metode Penelitian, ada beberapa poin yang kami tambahkan untuk memenuhi reviu proposal pada tahap *pre-processing* adalah sebagai berikut:

1. IMGT *web scrapping*:

Langkah pertama yang diperlukan untuk memperjelas alur teknik *pre-processing* yaitu proses ekstraksi data yaitu *scrapping*.

2. Pengumpulan Data dan Input:

Data IEDB yang telah terkumpul diformat agar menjadi input yang sesuai untuk model CNN

3. Normalisasi, klasifikasi, dan transformasi *DataFrame*:

Langkah ini diperlukan untuk melakukan normalisasi data (pembacaan oleh model), klasifikasi (manajemen data), konversi *tuple* untuk struktur data yang terorganisir.

LOGBOOK KEGIATAN PENELITIAN OPSI 2024

SMAN 4 DENPASAR-BALI

Nama Anggota Tim

: 1. Mirrabell Frederica Hadiwijono
2. I Nyoman Agung Ananda Terano

NIS


: 1. 11035
2. 11514


Bidang Lomba



: Fisika Terapan dan Rekayasa



Judul

: Prediksi Peptida Imunogenik untuk Imunitas Sel-T sebagai Epitop Potensial *Targeted-Vaccine* dan *Targeted-Immunotherapy* pada Kanker Paru Berbasis *Deep Learning* Menggunakan Algoritma *Convolutional Neural Network* (CNN)

No.	Hari/Tanggal	Aktivitas	Paraf Pembimbing
1	3 Februari 2024	Penemuan dan pembahasan masalah 	
2	10 Februari 2024	Konsultasi Ide Penelitian 	

3	5 Maret 2024	Pembuatan naskah proposal Penelitian 	
4	13 Maret 2024	Revisi dan evaluasi naskah proposal penelitian 	

5.	18 April 2024	Memperbaiki naskah proposal penelitian sesuai dengan rewiu yang diberikan juri. Reviu Ide proposal prediksi peptide imunogenik menggunakan CNN cukup menarik. Skema penelitian serta pembuatan arsitektur CNN juga sudah di gambarkan dengan baik. Namun, dalam tahap pre-processing data belum dijelaskan apa saja yang dilakukan. Harap dilengkapi dengan lebih detail Informasi Lainnya Lolos Seleksi Berkas : Ya Apakah proposal dapat lanjut ke proses penelitian ? : Ya	
6.	24 Mei 2024	Konsultasi naskah penelitian 	
7.	30 Mei 2024	Pengambilan data set 	

8.	10 Juni 2024	Pembuatan model <i>deep Learning</i> 	
9.	5 Agustus 2024	Training dan validasi output model <i>deep learning</i>	
10.	6 Agustus 2024	Pembuatan laporan Penelitian	
11.	20 Agustus 2024	Revisi naskah laporan penelitian 	

Denpasar, 8 September 2024

A handwritten signature in black ink, appearing to be 'Ni Made Margiani', written in a cursive style.

Ni Made Margiani,